

PROYECTO DE CLASIFICACIÓN

Predicción de Riesgo en Aprobación de Préstamos

Evaluación analítica y optimización de modelos de machine learning con infraestructura de despliegue y control de sobreajuste.

| Contexto y Objetivos Estratégicos

Enfoque Analítico

Construir, evaluar y optimizar diversos modelos de clasificación binaria enfocados en predecir la viabilidad del préstamo.

Requisito clave: Mantener el sobreajuste (overfitting) estrictamente por debajo del 5%.

Enfoque Productivo

Diseñar un ecosistema automatizado donde el modelo final sea exportado y puesto a disposición de un cliente final mediante una aplicación interactiva.

Ecosistema: App Streamlit, contenedores Docker, base de datos de feedback y pruebas unitarias.

| Auditoría de Calidad y Dataset

VARIABLE	TIPO	NULOS / ERRORES	ESTRATEGIA APLICADA
Income	Float	199 filas (Nulos & < 0)	Conversión a NaN + Imputación inteligente
CreditScore	Float	194 filas (Nulos)	Imputación estadística por mediana
LoanAmount	Float	28 filas (< 0)	Marcado de errores como NaN e imputación
Education	Object	198 filas (Nulos)	Asignación de categoría robusta 'Unknown'

11.4%


Filas con anomalías iniciales

Se implementó un filtrado preventivo y saneamiento antes del split del conjunto para mitigar la fuga de información (data leakage).


| Análisis de Valores Extremos (IQR)

Utilizando la metodología estadística de Tukey (Rango Inter cuartílico - IQR), se auditaron las variables clave para asegurar la estabilidad estadística de los modelos.

- ✓ **Edad (Age):** 0% de outliers. Distribución natural uniforme en el rango de 18 a 69 años.
- ✓ **Ingresos (Income):** 30 outliers identificados (0.65%). Truncado y tratamiento a límites aceptables de \$90,060.
- ✓ **Monto (LoanAmount):** 15 outliers detectados (0.33%). Límites superiores calculados en \$41,398.



| Distribución de la Variable Objetivo



Implicaciones de Negocio

El desbalance del target (aproximadamente 3:1) es común en carteras de crédito conservadoras donde el control de riesgos es estricto.

Esto exigió la aplicación de métricas de evaluación robustas como **F1-Score** y el área bajo la curva **ROC-AUC**, en lugar de guiarse únicamente por el Accuracy básico.

| Diseño del Pipeline de Preprocesado



Imputación Inteligente

Uso de `SimpleImputer` para manejar sistemáticamente los valores faltantes en campos financieros cruciales sin corromper la distribución.



Escalado Robusto

Normalización mediante `MinMaxScaler` y `StandardScaler` en variables continuas para ecualizar el peso de variables con magnitudes diferentes.



Encoding Unificado

Codificación categórica con `OneHotEncoder` para variables nominales y `OrdinalEncoder` mapeado para el nivel educativo estructurado.

| Rendimiento Comparativo de Modelos



El clasificador **XGBoost** superó significativamente a las alternativas, capturando dependencias no lineales de riesgo con mayor consistencia y eficiencia computacional.

| Optimización de Parámetros y Sobreajuste

✦ Tuning con Optuna

Implementación de búsqueda bayesiana de hiperparámetros con **Optuna** para maximizar el F1-Score.

Permite encontrar combinaciones de parámetros ideales con un menor coste de cómputo en comparación con GridSearch.


🛡 Control del Overfitting

Estricta limitación del sobreajuste mediante validación cruzada estructurada (**K-Fold**).

Diferencia de Métricas: < 4.1%

Cumple holgadamente el requisito estratégico de brecha de sobreajuste menor al 5%.

| Análisis de Importancia de Variables



Factores Decisores Clave

- ✔ **Credit Score (Puntaje Crediticio):** Representa una de las métricas numéricas más potentes para predecir la fiabilidad e historial de pago del aplicante.
- ✔ **Ratio Income (Nivel de Ingresos):** Los ingresos absolutos del solicitante se perfilan como el principal indicador de solvencia y capacidad general de financiamiento.
- ✔ **Employment Type (Tipo de Empleo):** La situación laboral, particularmente la condición de desempleo (`EmploymentType_Unemployed``), actúa como un factor crítico determinante en la evaluación de riesgo.

| Exportación de Modelo y Metadatos

Pipeline Serializado

Guardado del pipeline óptimo mediante la librería `joblib` para garantizar un despliegue libre de discrepancias en preprocesado.

```
joblib.dump(pipeline, 'model_risk_v1.pkl')
```

Registro de Metadatos

Generación de un archivo de configuración JSON que almacena las variables de entrada requeridas, métricas de validación y versión.

Asegura la trazabilidad y facilita las auditorías del modelo en entornos corporativos financieros.

| Arquitectura del Ecosistema de Despliegue



Contenedor Docker

Aislamiento total del entorno del modelo y la aplicación mediante contenedores, asegurando la reproducibilidad en servidores productivos.



Streamlit UI

Interfaz web reactiva y liviana para que agentes de crédito ingresen parámetros y obtengan aprobaciones instantáneas con explicabilidad visual.



Feedback Loop

Base de datos SQLite integrada para registrar entradas nuevas y recolectar feedback del personal humano, mejorando futuros reentrenamientos.

| Conclusiones y Siguietes Pasos

✔ Logros Técnicos

El sistema predictivo ha alcanzado con éxito todos los requerimientos estratégicos establecidos al inicio del desarrollo:

- ✔ **XGBoost Optimizado:** Logró un 94% de precisión con una brecha de sobreajuste de apenas 4.1%, cumpliendo holgadamente el límite del 5%.
- ✔ **Auditoría & Limpieza:** Saneamiento automatizado del 11.4% de los datos sin comprometer la integridad ni generar fugas de información.
- ✔ **Infraestructura Modular:** Pipeline completamente serializado, reproducible y empaquetado para su despliegue inmediato.

📈 Escalabilidad y Futuro

Para garantizar el valor continuo del modelo en un entorno financiero dinámico, se proponen las siguientes fases:

- ✔ **📈 Monitoreo de Data Drift:** Implementar alertas periódicas para detectar si las características de los aplicantes cambian con el tiempo.
- ✔ **🗄️ Integración SQLite/API:** El loop de feedback registrado permitirá enriquecer los conjuntos de datos de cara al reentrenamiento trimestral automático.
- ✔ **🗣️ Explicabilidad Local (SHAP):** Incorporar mapas visuales de importancia local para que el agente de crédito entienda la razón de cada rechazo individual.